UNIVERSIDADE FEDERAL DO CEARÁ

TECHNICAL REPORT

Aluno: Paulo Henrique Santos Marques

1. Introdução

O dataset apresentado contém informações sobre pacientes, incluindo suas idades, sexos, níveis de pressão arterial (BP), níveis de colesterol, relação sódio/potássio (Na_to_K) e o tipo de medicamento prescrito (Drug). O objetivo da classificação é determinar o tipo de medicamento (Drug) que foi prescrito para cada paciente com base nas outras características fornecidas.

As características relevantes do dataset incluem:

Idade = (Age): Representa a idade do paciente em anos. É uma variável numérica discreta.

Sexo = (Sex): Representa o gênero do paciente. É uma variável categórica que pode ser "M" para masculino ou "F" para feminino.

Pressão arterial = (BP): Representa o nível de pressão arterial do paciente. É uma variável categórica com três categorias possíveis: "LOW", "NORMAL" e "HIGH".

Colesterol = (Cholesterol): Representa o nível de colesterol do paciente. É uma variável categórica com duas categorias possíveis: "NORMAL" e "HIGH".

Relação sódio/potássio = (Na_to_K): Representa a relação entre os níveis de sódio e potássio do paciente. É uma variável numérica contínua.

Medicamento prescrito = (Drug): Representa o tipo de medicamento prescrito para o paciente. É uma variável categórica com cinco categorias possíveis: "drugY", "drugC", "drugX", "drugA" e "drugB".

UNIVERSIDADE FEDERAL DO CEARÁ

```
dtype: int64
     Age Sex      BP Cholesterol  Na_to_K   Drug
0     23   F    HIGH        HIGH   25.355  DrugY
1     47   M     LOW        HIGH   13.093  drugC
2     47   M     LOW        HIGH   10.114  drugC
3     28   F  NORMAL        HIGH    7.798  drugX
4     61   F     LOW        HIGH   18.043  DrugY
..   ...  ..     ...         ...      ...    ...
195   56   F     LOW        HIGH   11.567  drugC
196   16   M     LOW        HIGH   12.006  drugC
197   52   M  NORMAL        HIGH    9.894  drugX
198   23   M  NORMAL      NORMAL   14.020  drugX
199   40   F     LOW      NORMAL   11.349  drugX

[200 rows x 6 columns]
```

2. Observações

A base em si éra bem tranquila. Só precisei fazer uns procedimentos como fazer um pré processamento logo após a questão um, pois os metodos ultilizados na questão um, não havia sido o suficiente.

3. Resultados e discussão

Resultados esperados.

Em uma aplicação do classificador Knn, se espera uma acurácia com algum bom indice de desempenho do classifixador. Sgnifica que ao normalizar, processar, e fazer todos os procedimentos para que a base esteja pronta para o classificador, espera-se um resultado ao menos acima de 0,80, ou 80% no caso.

Sem normalizar os dados, foi efetuado uns testes no classificador, para ver como ele se saia sem essa técnica que normalmente faz com que o modelo tenha um melhor desempenho. No caso a “Normalização”.

Após os testes, tivemos até um score acima do esperado como mostra o resultado da questão 2:

```
Run: questao2
"C:\Paulo Henrique\IA\venv\Scripts\python.exe" "C:\Paulo Henrique\IA\AV1\questao2.py"
     Age  Sex  BP  Cholesterol  Na_to_K  Drug
0     23    0   0            0   25.355     0
1     47    1   1            0   13.093     1
2     47    1   1            0   10.114     1
3     28    0   2            0    7.798     2
4     61    0   1            0   18.043     0
..   ...  ...  ..          ...      ...   ...
195   56    0   1            0   11.567     1
196   16    1   1            0   12.006     1
197   52    1   2            0    9.894     2
198   23    1   2            1   14.020     2
199   40    0   1            1   11.349     2

[200 rows x 6 columns]
score:
 0.78

Process finished with exit code 0
```

Dando procefência.

Dado o resultado até razoável do classificador, diante dos dados se quer normalizados, iremos aplicar duas técnica de normalização bem conhecidas e uteis para melhorar o desempenho do knn.

```
198   23    1   2            1   14.020     2
199   40    0   1            1   11.349     2

[200 rows x 6 columns]
variancia:
 Age           272.345775
Sex             0.249600
BP              0.671900
Cholesterol     0.249775
Na_to_K        51.924606
dtype: float64
variancia do dataset normalizado:
 Age           1.0
Sex            1.0
BP             1.0
Cholesterol    1.0
Na_to_K        1.0
dtype: float64
Score com normalização de media zero e variância unitária 0.68 and  dados com normalização logarítmica 0.78
Nenhuma das duas normalizações conseguio obter uma acurácia tão superior aos dados não normalizados...

Process finished with exit code 0
```

Vejam que o resultado da questão 3 traz dados interessantes para se botar em questão.

Normalização: A saída mostra os resultados de duas formas de normalização aplicadas aos dados: normalização de média zero e variância unitária, e normalização logarítmica. É indicado que nenhuma das duas normalizações foi capaz de obter uma acurácia superior em comparação aos dados não normalizados.

Visto que a normalização é o foco;

Em resumo, a saída do código apresenta os resultados do modelo de aprendizado de máquina aplicado aos dados de entrada, incluindo a acurácia do modelo e informações sobre a variância dos dados original e normalizado, bem como a eficácia de diferentes técnicas de normalização aplicadas aos dados.

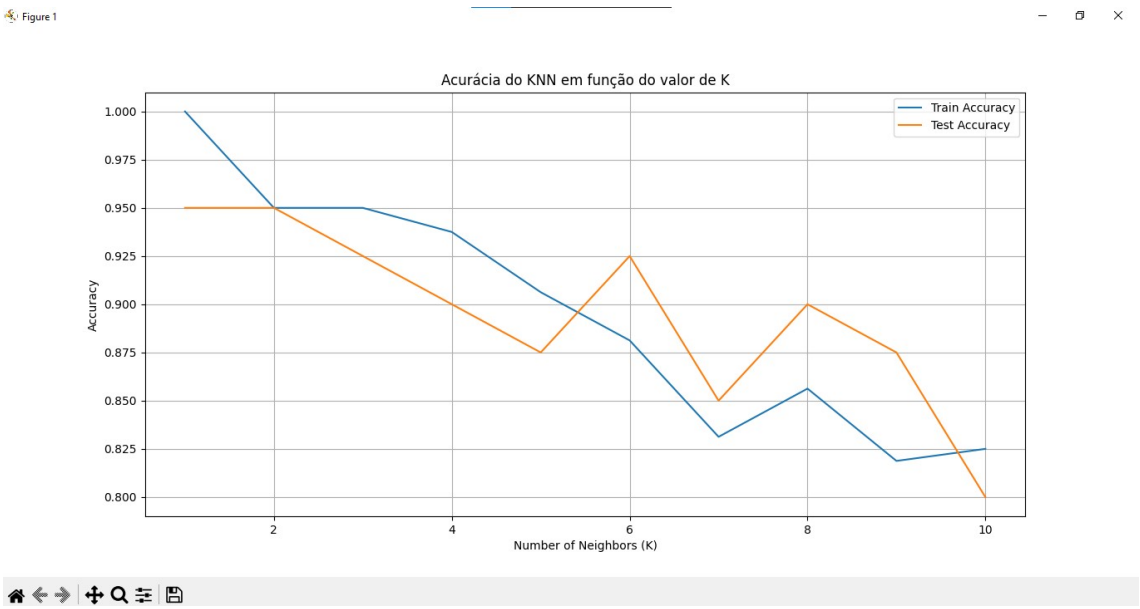

Na questão 4 obtivemos um gráfico, e em conjunto como output, um conjunto de valores k, na qual temos como objetivo identificar qual éra o melhor. Entre tanto com base nos gráficos e nas saidas obtidas, não consegui identificar, pois a estrutura do gráfico não éra para ter sido plotado assim. Quem sabe em estudos próximos, buscaremos saber qual o motivo do ocorrido.

4. Conclusões

De primeira, o Knn não se comportou como o esperado. Não foi possível identificar o melhor k de desempenho do classificador na base, e nem obter um bom indice de desempenho em questão de classificação da classe Drugs, em detrimento das características da base.

5. Próximos passos

Buscarei entender como ocorreu o resultado obtido não só no gráfico de desempenho do knn, mas se for o caso, buscar classificadores mais adequados para a base. Dado que dependendo do dataset, o Knn pode simplesmente não ser o ideal.